

CDS Agent 验收与下一阶段规划报告

目标：保留 MAP/CDS 控制面，把自研 agent loop 压缩为官方 SDK adapter。本次验收覆盖 CDS-managed Claude SDK runtime、OpenRouter/DeepSeek provider、只读代码巡检、安全边界、停止控制和工作台视觉。

验收结论

通过

commercialComplete=true

分支：codex/cds-agent-workbench-ui

提交：929e86db6

1. 总览

商业 gate

7/7

R0/A0/R1/S1/S2S3/V1/N6

one-cycle

10/1/0

pass / legacy skip / failed

总耗时

161s

真实 provider + 视觉 smoke

安全边界

0

Bash/Edit/Write 尝试与审批

2. 架构设计

MAP

控制面客户端：会话、UI、审计、审批、消息和事件读取。



CDS

容器、分支、runtime、sandbox 管理器。发现并调度 managed runtime。



Official SDK Adapter

Claude Agent SDK 执行 agent loop；本仓库只保留最薄 adapter、policy、observability。

设计原则 SSH、remote host、image、env 只保留为 operator/debug fallback，不进入普通用户主路径。

3. 当前能力边界

能力	结论	说明
只读代码巡检	可用	默认 OpenRouter DeepSeek Claude Code profile 已通过 S1。
可观察性	可用	runtime_init、tool_use、tool_result、done、assistant message 已回到 MAP。

可调试性	可用	one-cycle summary、execution ledger、progress board 已落地。
危险工具默认行为	收敛	默认 hardened-readonly 不暴露 Bash/Edit/Write。
改代码/跑测试/PR	下一阶段	需要 writable runtime profile、审批策略、diff/PR 产物闭环。

证据目录： /tmp/cds-agent-cycle-hardened-current

4. 验收矩阵

GATE	状态	验收内容	证据
R0	Pass	CDS-managed runtime capacity available, sharedRunning=1	cycle-summary.json
A0	Pass	官方 SDK adapter 主路径, 自研 loop 仅 legacy fallback	official SDK boundary
R1	Pass	默认 profile 兼容 claude-agent-sdk, 有 CDS-managed provider secret	OpenRouter DeepSeek V4 Pro · Claude Code
S1	Pass	真实 provider 只读仓库巡检, assistantMessages=1	/tmp/cds-agent-s1-provider-hardened.json
S2/S3	Pass	hardened-readonly 无危险工具; stop 返回 stopped	/tmp/cds-agent-controls-hardened.json
V1	Pass	工作台远端页面 HTTP 200, 文本和截图断言通过	workbench-visual.png
N6	Pass	非代码 Toolbox agents 不被 Claude SDK runtime 误接管	N6 smoke 27/27

5. 耗时分析

S1 provider run

58s, 最慢项。主要是真实模型读取仓库、上下文和输出。

S2/S3 controls

37s, 包含 S2 安全断言和 S3 stop。

V1 visual

32s, headless Chrome 打开远端工作台并截图。

6. 路径依赖

依赖	当前状态	影响
CDS self-update	已到 e0af6d2e 运行时代码, 文档到 929e86db6	runtime 已加载 hardened adapter; 文档和 smoke 脚本已推送。
CDS-managed runtime branch	shared-sidecar-pool-mp4anabh-cds-managed-runtime running	提供 Claude SDK sidecar runtime。
Provider profile	OpenRouter DeepSeek V4 Pro · Claude Code	只读巡检可用; 不要求 Anthropic 原生 key。
Writable profile	未启用	下一阶段改代码/PR 的前置条件。

origin/main

分叉 61/393

当前验收不依赖合 main；最终 PR 合并前必须做 merge/rebase 预检。

7. 是否需要合并 main

结论：当前验收不需要先合 main，因为验收目标是当前工作分支与远端 CDS runtime 的闭环，证据已经来自该分支。

合并前建议：在准备进入主线或 PR 前执行一次非破坏性预检：`git fetch origin`、检查 `origin/main...HEAD`、本地 merge/rebase dry-run、跑 one-cycle 或至少 S1/S2/S3/V1 窄验收。

8. 下一阶段规划：Writable Agent Cycle

W1 · 0.5 天

Writable profile 设计

把默认 read-only profile 与 writable profile 分离，定义工具白名单、审批策略、资源限制、审计字段。

W2 · 0.5-1 天

审批与工具策略

Bash/Edit/Write 只在 writable profile 中暴露；危险命令必须进入 MAP approval，不允许默认 auto-run。

W3 · 1 天

文件 diff / 测试 / 产物

把写入结果、diff、测试输出、失败重试和产物索引回传 MAP。

W4 · 0.5 天

PR 或补丁交付

先支持 patch/diff artifact，再接 GitHub PR。PR 权限独立开关，不进入默认 profile。

W5 · 0.5 天

验收

新增 S4 writable smoke：改一个小文件、跑测试、生成 diff、拒绝危险命令、stop/cancel、视觉截图。

9. 预计时间


最小可用 writable beta

2-3 天：支持受控写文件、跑限定测试、生成 diff artifact、人工审批、停止/取消和视觉验收。

接近商业级改代码/PR

4-6 天：补齐 PR 权限、回滚、失败重试、成本/耗时指标、并发隔离、完整 E2E 与回归报告。

10. 工作台视觉证据



11. 验收结论

已完成：默认 hardened read-only CDS Agent 可作为“上手即用”的代码巡检能力，具备可观察、可调试、可停止、可复跑和视觉验收证据。

未夸大：它还不是默认自动改代码/跑测试/提交 PR 的 agent；该能力需要下一阶段 writable profile，并且必须显式审批。

下一步：若目标是“审代码并给报告”，当前即可使用；若目标是“审代码并修改/提 PR”，进入 W1-W5 writable cycle。

生成时间：2026-05-19 Asia/Shanghai · HTML 源文件：doc/report.cds-agent-acceptance-visual-2026-05-19.html · PDF 输出：doc/report.cds-agent-acceptance-visual-2026-05-19.pdf